

PSA

1. Náhodný pokus a náhodný jev. Operace s náhodnými jevy
2. Pravděpodobnost a její vlastnosti. Klasická definice ppsti. Geometrická definice ppsti.
3. Axiomatická definice ppsti.
4. Nezávislost jevů. Podmíněná pravděpodobnost.
5. Věta o úplné pravděpodobnosti. Bayesova věta.
6. Náhodná veličina obecně, a speciálně DISKRÉTNÍHO a SPOLITÉHO TYPU.
7. Funkce hustoty a její vlastnosti. Pravděpodobnostní funkce a její vlastnosti.
8. Distribuční funkce a její vlastnosti. Kvantilová funkce a kvantily.
9. Charakteristiky polohy: střední hodnota, medián. Obecné a centrální momenty.
10. Charakteristiky variability: rozptyl, kvantilové rozpětí, variační koeficient. Šířka a spícatost.
11. Binomické rozdělení. Hypergeometrické rozdělení.
12. Poissonovo rozdělení. Vztah Poissonova a exponenciálního rozdělení.
13. Rovnoměrné rozdělení. Exponenciální rozdělení.
14. Normální rozdělení. Rozdělení odvozené od normálního.
15. Vztahy mezi základními typy rozdělení.
16. Nezávislost náhodných veličin. Vícerozměrná rozdělení. Kovariance a korelace.
17. Vícerozměrné normální rozdělení.
18. Centrální limitní věta.
19. Transformace náhodných veličin.
20. Rozdělení minim a maxim náhodných veličin. Rozdělení součtu náhodných veličin.
21. Popisná statistika. Základní statistické grafy.
22. Náhodný výběr. Výběrové statistiky a jejich statistiky.
23. Bodové a intervalové odhady. Vlastnosti odhadů
24. Bodové odhady. Konstrukce odhadu metodou momentů a metodou maximální věrohodnosti.
25. Formulace statistických hypotéz. Chyba I. a II. druhu u statistických testů.
26. Statistická testování. Kritický bod. P-hodnota statistických testů.
27. Jednovýběrové parametrické testy.
28. Dvouvýběrové parametrické testy.
29. χ^2 test dobré shody.
30. Testování nezávislosti.
31. Formulace lineárního regresního modelu. Maticový zápis modelu.
32. Odhad parametrů lineárního regresního modelu. Gauss Markova věta.
33. Koeficient determinace.
34. Testování koeficientů lineárního regresního modelu.

① **NÁHODNÝ POKUS** • libovolný proces, jehož výsledek nemá jednoznačně určené podmínkami, za nichž je prováděn. lze popsat množinou možných výsledků pokusu Ω

- proces, kde může nastat 2 nebo více výsledků (za stejných TP)
- hod testu, dotaz respondenta

NÁHODNÝ JEV = jakákoliv ověřitelná tvrzení o výsledku náhodného pokusu.

- „Nastal jev A.“ \rightarrow A je pravdivé tvrzení o výsledku náhodného pokusu.
- $A \subset \Omega$

Všechny možné, dále nerozložitelné výsledky náhodného pokusu nazýváme **elementární jevy** - značíme ω .
Obvykle volíme elementární jevy tak, aby každý jev A bylo možno napsat „pomocí“ elementárních jevů.

$$A = \{\omega_1\} \cup \{\omega_2\} \cup \dots$$

Elementární jevy jsou disjunktí, tj. pro libovolné el. jevy platí: $\{\omega_1\} \cap \{\omega_2\} = \emptyset$.

Systém el. jevů je úplný, tj. $\Omega = \bigcup_{i=1}^{\infty} \{\omega_i\}$

OPERACE S JEVI - s jevy pracujeme jako s množinami (Vénny diagramy)

Ω - jev jistý

\emptyset - jev nemožný

$\bar{A} (A^c, A')$ doplněk jevu $\Omega - A \rightarrow$ neprobí A





$A \cap B$ průnik jevů \rightarrow A a zároveň B

$A \cup B$ sjednocení jevů \rightarrow A nebo B (nebo oba)

$A \subset B$ A je podjevem B \rightarrow když A, pak vždy B

$A \cap B = \emptyset$ neslučitelné (disjunktí) jevy

$A_1 \cup A_2 \cup \dots \cup A_m = \Omega$ systém úplných jevů \rightarrow všechny situace, které mohou nastat



VLASTNOSTI JEVŮ

1) KOMUTATIVITA $A \cup B \equiv B \cup A$ $A \cap B \equiv B \cap A$

2) ASOCIATIVITA $(A \cup B) \cup C \equiv A \cup (B \cup C)$ $(A \cap B) \cap C \equiv A \cap (B \cap C)$

3) DISTRIBUTIVITA $(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$ $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$

4) COMPLEMENT $A \cap \bar{A} = \emptyset$ $A \cup \bar{A} = \Omega$

5) DE MORGANOVA PRAVIDLA $\overline{A \cup B} = \bar{A} \cap \bar{B}$ $\overline{A \cap B} = \bar{A} \cup \bar{B}$

- ② **Pravděpodobnost** $P(A)$
- každému jevu A přiřazuje reálné číslo $P(A)$
 - lze ji chápat jako předpověď poměrných četností výsledků při mnohonásobném opakování daného pokusu
 - lze ji interpretovat jako kvantitativní ohodnocení stupně jistoty

Vlastnosti pravděpodobnosti Je-li $A, B \in \mathcal{A}$, pak platí:

1) $0 \leq P(A) \leq 1$ $P(\emptyset) = 0$ $P(\Omega) = 1$

2) ppst doplnku: $P(\bar{A}) = 1 - P(A)$

3) ppst sjednocení: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$  - průnik je dx \rightarrow musím 1x odečíst

4) pro $A \subset B$: $P(A) \leq P(B)$

Limitní vlastnosti ppsti: a) Jsou-li $A_1 \subset A_2 \subset \dots \subset A_n \subset \dots$ pak $P(\bigcup_{n=1}^{\infty} A_n) = \lim_{n \rightarrow \infty} P(A_n)$

b) Jsou-li $A_1 \supset A_2 \supset \dots \supset A_n \supset \dots$ pak $P(\bigcap_{n=1}^{\infty} A_n) = \lim_{n \rightarrow \infty} P(A_n)$

• KLASICKÁ DEFINICE PRAVDĚPODOBNOSTI

Nechť Ω obsahuje konečný počet stejně možných elementárních jevů, pak ppst A :

$$P(A) = \frac{\text{počet příznivých výsledků}}{\text{počet všech možných výsledků}}$$

GEOMETRICKÁ DEFINICE PRAVDĚPODOBNOSTI

Nechť prostor Ω lze vyjádřit jako plochu v \mathbb{R}^2 , pak ppst A :

$$P(A) = \frac{\text{obsah plochy } A}{\text{obsah plochy } \Omega}$$

Relativní četnost - statistická definice ppsti

Uvažujeme sérii m nezávislých náhodných pokusů, pak relativní četnost jevu A je

$$\frac{\text{počet pokusů, kdy výsledek je } A}{\text{počet všech pokusů} = m}$$

③ KOLMOGOROVOVA AXIOMATICKÁ DEFINICE PPSTI

Trojice (Ω, \mathcal{A}, P) nazýváme **pravděpodobnostní prostor**, pokud platí

i) \mathcal{A} je σ -algebra podmnožin množiny Ω , tj. \mathcal{A} je **systém podmnožin**, pro které platí

• je-li $A \in \mathcal{A}$, pak také $\bar{A} \in \mathcal{A}$

• jsou-li $A_i, i=1,2,\dots \in \mathcal{A}$, pak i $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$

ii) P je funkce, pro kterou platí

• $P(\Omega) = 1$

• $P(A) \geq 0$

• pro $\{A_i, i=1,2,\dots\}$ takové, že $A_i \cap A_j = \emptyset$ pro $i \neq j$ platí $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$

klasická definice ppsti je speciálním případem axiomatické definice, kdy $\Omega = \{\omega_1, \dots, \omega_n\}$, \mathcal{A} jsou všechny podmnožiny množiny Ω a $P(\{\omega_1\}) = \dots = P(\{\omega_n\}) = 1/n$

④ Dva nezávislé jevy, párová nezávislost:

Dva jevy A a B jsou nezávislé, jestliže $P(A \cap B) = P(A) \cdot P(B)$

Pozor! rozlišovat nezávislé jevy a disjunktí jevy $\rightarrow A \cap B = \emptyset \rightarrow P(A \cap B) = P(\emptyset) = 0$

Vlastnosti nezávislých jevů: pro dva nezávislé jevy A a B platí

i) $P(A|B) = P(A)$ $P(B|A) = P(B)$

ii) $P(A \cup B) = P(A) + P(B) - P(A) \cdot P(B)$

iii) jevy \bar{A} a \bar{B} jsou nezávislé, jevy A a \bar{B} jsou nezávislé, jevy \bar{A} a B jsou nezávislé

Nezávislost více jevů, sdružená nezávislost

Náhodné jevy A_1, A_2, \dots jsou (sdruženě) nezávislé, jestliže $P(B \cap C)$ a každou k-tici náhodných jevů A_{i_1}, \dots, A_{i_k} platí:

$$P\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k P(A_{i_j})$$

Z párové nezávislosti NEPLYNE sdružená nezávislost.

Podmíněná pravděpodobnost

Podmíněná pravděpodobnost jevu A za podmínky jevu B (kde $P(B) > 0$) je

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

pozn. $P(A|B) \neq P(B|A)$

$$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

úplný systém disjunktí jevů:

Systém jevů A_1, A_2, \dots nazveme úplný systém disjunktí jevů pokud platí

$$\bigcup_{i=1}^{\infty} A_i = \Omega \text{ a } A_i \cap A_j = \emptyset \text{ pro } i \neq j$$

⑤ Věta O ÚPLNÉ PRAVDĚPODOBNOSTI

Je-li A_1, A_2, \dots takový úplný systém disjunktí jevů, že platí $P(A_i) > 0$, $i=1, 2, \dots$ pak:

$$P(B) = P(B|A_1) \cdot P(A_1) + P(B|A_2) \cdot P(A_2) + P(B|A_3) \cdot P(A_3) + \dots = \sum_i P(B|A_i) \cdot P(A_i)$$

BAYESŮV VZOREC (O INVERZNÍ PRAVDĚPODOBNOSTI)

Je-li A_1, A_2, \dots takový úplný systém disjunktí jevů, že platí $P(A_i) > 0$, $i=1, 2, \dots$ a pokud $P(B) > 0$ pak

$$P(A_j|B) = \frac{P(B|A_j) \cdot P(A_j)}{\sum_i P(B|A_i) \cdot P(A_i)} = \frac{P(B|A_j) \cdot P(A_j)}{P(B)} \quad \forall j=1, 2, \dots$$

DŮKAZ: $P(A_i|B)P(B) = P(B|A_i)P(A_i)$
 $P(A_1 \cap B) = P(B \cap A_1)$


Spolehlivost PARALELNĚ a SÉRIOVĚ řazených nezávislých prvků

• Necht' p_1, p_2, \dots, p_m jsou ppsti poruch prvků P_1, P_2, \dots, P_m .
 Předpokládáme, že poruchy jednotlivých prvků jsou na sobě nezávislé.

PARALELNÍ - označme $P_1, P_2, P_3, \dots, P_m$

Pravděpodobnost poruchy systému: $P = P_1 \cdot P_2 \cdot \dots \cdot P_m = \prod_{i=1}^m P_i$

Spolehlivost systému: $R = 1 - P = 1 - \prod_{i=1}^m P_i$



- systém funkční, pokud alespoň 1 prvek funkční
- pravděpodobnost poruchy systému je ppst toho, že dojde k poruše všech prvků

SÉRIOVÉ - označme P_1, P_2, \dots, P_m

Pravděpodobnost poruchy systému:

$$P = 1 - (1 - P_1) \cdot (1 - P_2) \cdot \dots \cdot (1 - P_m) = 1 - \prod_{i=1}^m (1 - P_i) = 1 - R$$

Spolehlivost systému:

$$R = 1 - P = (1 - P_1) \cdot (1 - P_2) \cdot \dots \cdot (1 - P_m) = \prod_{i=1}^m (1 - P_i)$$



- systém funkční, pokud VŠECHNY prvky funkční
- ppst poruchy systému je ppst toho, že dojde k poruše ALESPŮ 1 prvku
- ppst fungování systému je ppst toho, že fungují VŠECHNY prvky

6) NÁHODNÁ VELIČINA

Máme pravděpodobnostní prostor (Ω, \mathcal{A}, P) pak reálnou měřitelnou funkcí $X: \Omega \rightarrow \mathbb{R}$ nazveme NÁHODNÁ

VELIČINA (křítelná funkce $x \in \mathbb{R} \Rightarrow [X \leq x] \in \mathcal{A}$)

- výsledkem náhodného pokusu (náhodným jevem) přiřazujeme reálné číslo
- náhodnou veličinu značíme velkými latinskými písmeny z konce abecedy X, Y, Z / nebo x_1, x_2 ,
nebo vybranými písmeny řecké abecedy ξ (ksi), η (eta), ζ (dzeta)
- realizace NV (je známa až po provedení náhodného pokusu) značíme malými písmeny x, y, z / x_1, x_2, \dots
- rozdělení NV = popis charakterizující pravděpodobnostní chování NV
- zápis $P(X=x)$ čteme „NV X nabývá hodnoty x “

DISKRÉTNÍ NV

Pokud existují vesměs různá čísla x_1, x_2, \dots taková, že $\sum_{i=1}^{\infty} P(X=x_i) = 1$, pak náhodnou veličinu nazýváme DISKRÉTNÍ.

Funkce $P(x) = \begin{cases} P(X=x_i) & \text{pro } x=x_i, i=1,2,\dots \\ 0 & \text{pro } x \neq x_i \end{cases}$ se nazývá PRAVĚPODOBNOSTNÍ



- počítání pravděpodobností respektuje distribuci (uvážejme $x_{(1)} < x_{(2)} < x_{(3)} < \dots$)

$$P(X \leq x_i) = F(x_i) = P(X=x_1) + P(X=x_2) + \dots + P(X=x_i)$$

$$P(X < x_i) = F(x_{i-1}) = P(X=x_1) + P(X=x_2) + \dots + P(X=x_{i-1})$$

$$P(X \geq x_i) = 1 - P(X < x_i) = 1 - F(x_{i-1})$$

$$P(X > x_i) = 1 - P(X \leq x_i) = 1 - F(x_i)$$

SPOJITÁ NV

Řekneme, že NV X je SPOJITÁ, pokud existuje funkce f tak, že $F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$

Funkci f nazýváme FUNKCÍ HUSTOTY náhodné veličiny X .

- počítání pravděpodobností:

$$P(X=a) = 0$$

$$P(X \leq a) = P(X < a) = F(a) = \int_{-\infty}^a f(t) dt$$

$$P(X \geq a) = P(X > a) = 1 - F(a) = \int_a^{\infty} f(t) dt$$

$$P(a < X < b) = P(a \leq X \leq b) = F(b) - F(a) = \int_a^b f(t) dt$$

pravděpodobnost lze interpretovat jako obsah plochy pod funkcí hustoty

④ FUNKCE HUSTOTY


$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

vlastnosti distribuční funkce a funkce hustoty pro spojitou NV

i) $f(x) = F'(x)$ pro skoro všechna x

ii) $f(x) \geq 0$ skoro vsude a $\int_{-\infty}^{\infty} f(t) dt = 1$

iii) každá mezípořadná (měřitelná) funkce $f(x)$ taková, že $\int_{-\infty}^{\infty} f(t) dt = 1$ je hustotou nějaké NV.



⑤ PRAVDĚPODOBNOSTNÍ FUNKCE

funkce $P(x) \begin{cases} P(X=x_i) & x=x_i, i=1,2,\dots \\ 0 & x \neq x_i \end{cases}$

⑧ DISTRIBUČNÍ FUNKCE $x \in \mathbb{R}$ je distribuční fce NV x definovaná $F(x) = P(X \leq x)$




Vlastnosti: i) $0 \leq F(x) \leq 1$

ii) $\lim_{x \rightarrow -\infty} F(x) = 0$ a $\lim_{x \rightarrow +\infty} F(x) = 1$

iii) $F(x)$ je NEKLESAJÍCÍ na \mathbb{R}

iv) $F(x)$ je zprava spojité

v) $F(x)$ má nejvýše početně bodů nespojitosti



Vlastnosti distribuční a pravděpodobnostní funkce pro DISKRÉTNÍ NV

i) distribuční fce je PO ČÁSTECH KONSTANTNÍ

$$F(x) = \sum_{x_i \leq x} P(X=x_i) = \sum_{x_i \leq x} P(x_i)$$

$$P(X=x_i) = F(x_i) - \lim_{x \rightarrow x_i^-} F(x)$$

KVANTILOVÁ FUNKCE A KVANTIL


Pro hodnotou veličinu X s distribuční funkcí $F(x)$ je kvantilová funkce dána vztahem

$$F^{-1}(u) = \inf \{x \in \mathbb{R} : F(x) \geq u\}, \quad 0 < u < 1$$

Pro $0 < u < 1$ se hodnota $F^{-1}(u)$ nazývá α -kvantil.

α -kvantile značíme x_α :

- 0.5 kvantil - medián
- 0.25 kvantil - dolní kvartil
- 0.75 kvantil - horní kvartil



Pro spojitou NV je kvantilová funkce inverzní k $F(x)$

• kvantilová funkce je neklesající a pokud je distribuční funkce SPJITÁ a OSTŘE ROSTOUCÍ, pak kvantilová funkce je lokožná s obvyklou inverzní funkcí k funkci F .

• Pro kvantily platí: $F(x_\alpha) = \alpha$ (speciálně pro medián $F(x_{0.5}) = 0.5$)

9) CHARAKTERISTIKY POLOHY:

• STŘEDNÍ HODNOTA - pro diskrétní NV: $E[X] = \sum_{i=1}^{\infty} x_i \cdot P(X=x_i)$

pokud součet řady, resp. integrál existuje

- pro spojitou NV: $E[X] = \int_{-\infty}^{\infty} x \cdot f(x) dx$

vlastnosti - pro náhodné NV X a Y ; pro které existují střední hodnoty a pro libovolné $c \in \mathbb{R}$ platí

i) $E[c] = c$

ii) $E(cX) = cEX$

iii) $E(X+Y) = EX + EY$

iv) $P(X \leq Y) = 1 \rightarrow EX \leq EY$

• MEDIÁN - α -kvantil, $F(x_{0.5}) = 0.5$

$$x_{0.5} = F^{(-1)}(0.5) = \inf \{x \in \mathbb{R} : F(x) \geq 0.5\}$$

MOMENTY NÁHODNÉ VELICINY - Pro náhodnou veličinu X a přirozené číslo n definujeme

n -tý obecný moment $\mu'_n = E(X^n)$

n -tý centrální moment $\mu_n = E[(X - EX)^n]$

10) CHARAKTERISTIKY VARIABILITY:

• ROZPTYL - rozptyl NV X je definován vztahem $D[X] = E[(X - EX)^2]$

směrodatná odchylka σ_X je odmocnina z rozptylu

Vlastnosti rozptylu - Pro NV X , pro kterou existují rozptyl a pro libovolné $a \in \mathbb{R}$ platí:

i) $D[X] \geq 0$ a navíc $D[X] = 0 \iff \exists c \in \mathbb{R} : P(X=c) = 1$

↳ důsledek $D[c] = 0$

ii) $D[X] = E(X^2) - (EX)^2$

iii) $D(cX) = c^2 D(X)$

$D(X+Y) = D[X] + D[Y]$ - platí pro nezávislé NV

- výpočtový tvar pro DISKRÉTNÍ: $D[X] = \sum_{i=1}^{\infty} x_i^2 \cdot P(X=x_i) - (EX)^2$

pro SPOJITOU: $D[X] = \int_{-\infty}^{\infty} x^2 \cdot f(x) dx - (EX)^2$

• KVANTILOVÉ ROZPĚTÍ $ICQ = x_{0.75} - x_{0.25}$
 $= F^{-1}(0.75) - F^{-1}(0.25)$

• VARIANČNÍ KOEFICIENT $CV(X) = \frac{\text{std}(X)}{EX}$

ČEBYŠEVŮVA NEROVNOST Nechť $D[X] < \infty$ a nechť $E > 0$, pak platí: $P(|X - EX| \geq E) \leq \frac{D[X]}{E^2}$

• KOEFICIENT ŠÍŘKOSTI $\gamma_3 = \frac{\mu_3}{(\sqrt{D[X]})^3}$ ← 3. centrální moment

ŠPÍČATOST

$\gamma_4 = \frac{\mu_4}{(D[X])^2} - 3$ ← 4. centrální moment

11) BINOMICKÉ ROZDĚLENÍ: $X \sim Bi(n, p)$
 popisuje # úspěchů při n opakování
 počet opakování
 ppst. úspěchu v jednom (každém) opakování

parametry $p \in (0, 1)$, $n \in \mathbb{N}$, množina $X \in \{0, 1, 2, 3, 4, 5, \dots, n\}$

ppstní funkce: $P(X=k) = \binom{n}{k} p^k (1-p)^{n-k}$

střední hodnota: $EX = np$, rozptyl: $DX = np(1-p)$

poznámky: $A_i \sim A(p)$, $i=1, 2, \dots, n$ nezávislé veličiny $\Rightarrow X = \sum_{i=1}^n A_i \sim Bi(n, p)$

$Bi(n, p=1/2)$ - symetrické, $Bi(n, p \neq 1/2)$ - nesymetrické

ppst. úspěchu v 1 pokusu je p , $\forall X \sim Bi(n, p)$ charakterizuje # úspěšných pokusů při n nezávislých opakováních

podíl výrobků s danou vlastností je v základním souboru p , $\forall X \sim Bi(n, p)$ charakterizuje # výrobků s danou vlastností ve výběru rozsahu n , pokud prvky **VRACÍME ZPĚT**

\rightarrow ALTERNATIVNÍ (BERNOULLIHO): $X \sim A(p)$, $p \in (0, 1) \rightarrow X \in \{0, 1\}$

ppstní funkce: $P(X=j) = p^j \cdot (1-p)^{1-j}$, $EX = p$, $DX = p(1-p)$

poznámky: rozdělení alternativního jevu, platí X neprobíhá

- speciální případ BINOMICKÉHO, kde $n=1$

HYPERGEOMETRICKÉ ROZDĚLENÍ $X \sim HG(N, K, n)$ rozsah výběru

počet prvků se sledovanou vlastností ve výběru

rozsah souboru


počet prvků v základním souboru se sledovanou vlastností

parametry: $0 < K < N$; $0 < n \leq N$; $n, K, N \in \mathbb{N}$, $X \in \{0, 1, 2, \dots, \min(K, n)\}$

ppstní funkce: $P(X=k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$, kde $k=0, 1, 2, \dots, \min(K, n)$

VÝBĚR BEZ OPAKOVÁNÍ

$EX = n \cdot \frac{K}{N}$, $DX = n \cdot \frac{K}{N} \left(1 - \frac{K}{N}\right) \frac{N-n}{N-1}$



poznámky: pokud značíme $p = K/N$ procento prvků se sledovanou vlastností v souboru a dále uvažujeme, že vybraných prvků je „tak moc“, že nezáleží na tom, zda po výběru prvek vracíme či ne $\Rightarrow HG(N, K, n) \approx Bi(n, p = \frac{K}{N})$ stačí $n \geq 30$, $p \leq 0,1$

12) POISSONOVO ROZDĚLENÍ $X \sim Po(\lambda)$, $\lambda > 0$, $X \in \{0, 1, 2, \dots\}$ - nekonečně spočetné


pmf: $P(X=k) = e^{-\lambda} \cdot \frac{\lambda^k}{k!}$, kde $k=0, 1, 2, \dots$

$$EX = \lambda = DX$$

- poznámky:
- uvažujeme náhodně se vyskytující událost, přesněji počet výskytu události během časového intervalu je PŘÍMO ÚMĚRNÁ DĚLCE časového intervalu, průměrný počet výskytu události za konstantní jednotku času λ , pak NV $X \sim Po(\lambda)$ charakterizují počet výskytu události za konstantní časovou jednotku
 - rozdělení počtu úspěchů při velkém počtu nezávislých experimentů s malou pravděpodobností úspěchu
 - pro $n \rightarrow \infty$ a $p \rightarrow 0$ je $Bi(n, p) \sim Po(\lambda = np)$ - stačí $n \geq 30$, $p \leq 0,1$

vztah Poissonova a exponenciálního rozdělení:


jestliže se počet výskytů události během nějakého časového intervalu řídí Poiss. rozdělením s parametrem λ , pak doba mezi výskytem 2 událostí se řídí EXP. ROZDĚLENÍM s $\delta = \frac{1}{\lambda}$



13) ROVNOMĚRNÉ ROZDĚLENÍ $X \sim U(a, b)$, $a, b \in \mathbb{R}$, $a < b$, $X \in (a, b)$

funkce hustoty:

$$f(x) = \begin{cases} \frac{1}{b-a} & x \in (a, b) \\ 0 & \text{jinde} \end{cases}$$




• střední hodnota:

$$EX = \frac{a+b}{2}$$

distribuční funkce:

$$F(x) = \begin{cases} 0 & x \leq a \\ \frac{x-a}{b-a} & x \in (a, b) \\ 1 & x \geq b \end{cases}$$




• rozptyl: $DX = \frac{(b-a)^2}{12}$

Nechť $X \sim U(a, 1)$ a F spojitá distribuční fu. Pak NV $Y = F(X)$ má rozdělení s distr. fu F .

poznámky: NV X může být libovolné reálné hodnoty z intervalu (a, b) a její výskyt na celém intervalu (a, b) je stejně možný


EXPONENCIÁLNÍ ROZDĚLENÍ $X \sim Exp(\delta)$, $\delta > 0$, $X \in (0, +\infty)$

funkce hustoty $f(x) = \begin{cases} \frac{1}{\delta} \cdot e^{-x/\delta} & x \geq 0 \\ 0 & x < 0 \end{cases}$



distribuční funkce

$$F(x) = \begin{cases} 0 & x < 0 \\ 1 - e^{-x/\delta} & x \geq 0 \end{cases}$$




$$EX = \delta, DX = \delta^2$$

poznámky: popisují například dobu čekání na určitou náhodnou událost nebo dobu životnosti součástek, které nepodléhají opotřebení. Parametr δ charakterizuje průměrnou dobu mezi výskytem dvou událostí.

⑭ NORMÁLNÍ ROZDĚLENÍ (GAUSSOVO) $X \sim N(\mu, \sigma^2)$, $\mu, \sigma^2 \in \mathbb{R}$, $\sigma^2 > 0$, $x \in \mathbb{R}$


funkce hustoty: $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{1}{2} \cdot \frac{(x-\mu)^2}{\sigma^2}}$

$x \in \mathbb{R}$



Distribuční fce - může vyjádřit pomocí elementárních funkcí

$EX = \mu$, $DX = \sigma^2$



poznámky: NORMOVANÉ NORMÁLNÍ ROZDĚLENÍ $N(\mu=0, \sigma^2=1)$,

značíme obvykle U a příslušnou funkci hustoty značíme $\varphi(u)$, distribuční funkci $\Phi(u)$

• funkce hustoty symetrická kolem μ , tedy pro $x \in \mathbb{R}$: $F(x-\mu) = 1 - F(x+\mu)$

• symetrické funkce hustoty a distribuční funkce pro NORMOVANÉ \bar{x}

$\varphi(-u) = \varphi(u)$

$\Phi(u) = 1 - \Phi(-u)$

věta: nechť $X \sim N(\mu, \sigma^2)$, pak $U = \frac{X-\mu}{\sigma} \sim N(0,1)$ a platí:

i) pro hodnoty distribuční funkce $F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$

ii) pro kvantily $x_k = \mu_k \cdot \sigma + \mu$

pravidlo 3-sigma - pro NV $X \sim N(\mu, \sigma^2)$ a číslo $k \in \mathbb{N}$ platí:

$P(\mu - k \cdot \sigma < X < \mu + k \cdot \sigma) = F(\mu + k \cdot \sigma) - F(\mu - k \cdot \sigma) = \Phi(k) - \Phi(-k) = 2 \cdot \Phi(k) - 1$

Speciálně: $P(\mu - \sigma < X < \mu + \sigma) = \frac{2}{3}$

$P(\mu - 2\sigma < X < \mu + 2\sigma) = 0,95$

$P(\mu - 3\sigma < X < \mu + 3\sigma) = 0,997$

⑮ Vztahy mezi základními typy rozdělení.



$1(p) = Bi(n=1, p)$

$HG(N, h, n) \approx Bi(p = \frac{N}{n}, n)$

$Bi(n, p) \approx Po(\lambda = n \cdot p)$

$N(\mu = n \cdot p, \sigma^2 = n \cdot p \cdot (1-p))$

$Po(\lambda) \approx N(0, \lambda)$

16) NEZÁVISLOST NÁHODNÝCH VELIČIN

→ NV X_1, X_2, \dots, X_n jsou nezávislé, když $\forall x_1, x_2, \dots, x_n$ jsou nezávislé gvy $[X_1 \leq x_1], [X_2 \leq x_2], \dots, [X_n \leq x_n]$

- NV X a Y jsou nezávislé právě tehdy, když $\forall x, y \in \mathbb{R}^2$ platí

$$F(x, y) = F_X(x) \cdot F_Y(y) \quad \text{— lze rozšířit pro } n \text{ nezávislých veličin}$$

$$P(X \leq x_i \wedge Y \leq y_j) = P(X \leq x_i) \cdot P(Y \leq y_j)$$

- DISKRÉTNÍ NV X a Y jsou nezávislé právě tehdy, když

$$P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j) \quad \forall i, j = 1, 2, \dots$$

- SPOJITÉ NV X a Y jsou nezávislé právě tehdy, když

$$f(x, y) = f(x) \cdot f(y) \quad \forall (x, y) \in \mathbb{R}^2$$

VÍCEROZMĚRNÁ NÁHODNÁ VELIČINA - NÁHODNÝ VEKTOR

- SDRUŽENÁ DISTRIBUTUČNÍ FUNKCE - pro NV X_1, X_2, \dots, X_n se funkce $F(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$ nazývá sdrúžená distribuční funkce

— distribuční funkce jednotlivých veličin se nazývají marginální distribuční funkce

- SDRUŽENÁ FUNKCE HUSTOTY

— pro SPOJITÉ NV se funkce $f(x_1, x_2, \dots, x_n) = \frac{\partial^n F(x_1, x_2, \dots, x_n)}{\partial x_1 \partial x_2 \partial x_3 \dots \partial x_n}$ nazývá sdrúžená funkce hustoty

— dvourozměrná DISKRÉTNÍ NV - tabulka

$X \backslash Y$	y_1	y_2	y_n
x_1	$P(x_1, y_1)$	$P(x_1, y_2)$	$\dots P(x_1, y_n)$
x_2	$P(x_2, y_1)$	$P(x_2, y_2)$	$\dots P(x_2, y_n)$
\vdots			
x_m	$P(x_m, y_1)$	$P(x_m, y_2)$	$\dots P(x_m, y_n)$

- Vlastnosti sdrúžené distribuční funkce

- $0 \leq F(x_1, \dots, x_n) \leq 1$

- měklesající, zprava spojitá $\forall x_i$

- $\lim_{x_i \rightarrow -\infty} F(x_1, \dots, x_n) = 0 \quad \forall i = 1, 2, \dots, n$

$$\lim_{x \rightarrow \infty} F(x) = 1 \quad \text{kde } x \rightarrow \infty \text{ znamená } x_i \rightarrow \infty \quad \forall i = 1, 2, \dots, n$$

- Vlastnosti marginálních funkcí - uvažujeme dvourozměrnou NV (X, Y) , pak pro marginální distribuční funkce platí:

$$F_X(x) = \lim_{y \rightarrow \infty} F(x, y) \quad F_Y(y) = \lim_{x \rightarrow \infty} F(x, y)$$

- pro DISKRÉTNÍ NV s pravděpodobnostní funkcí $P(X = x_i, Y = y_j)$, kde $i = 1, 2, \dots, m \quad j = 1, 2, \dots, n$

$$P_X(X = x_i) = \sum_j P(X = x_i, Y = y_j) \quad P_Y(Y = y_j) = \sum_i P(X = x_i, Y = y_j)$$

- pro SPOJITOU NV s funkcí hustoty $f(x, y)$

$$f_X(x) = \int_{\mathbb{R}} f(x, y) dy \quad f_Y(y) = \int_{\mathbb{R}} f(x, y) dx$$

CHARAKTERISTIKY VÍCEROZMĚRNÉ NV

- střední hodnota náhodného vektoru X je vektor středních hodnot marginálních rozdělení $EX = (EX_1, EX_2, \dots)$

- rozptyl náhodného vektoru X je vektor $DX = (DX_1, DX_2, \dots)$

pro nezávislé NV X a Y platí: $EX \cdot Y = EX \cdot EY$

$$D(X \pm Y) = DX \pm DY$$

Budeme předpokládat, že NV mají konečné druhé momenty \rightarrow tedy i konečné první momenty:
 ze Schwarzovy nerovnosti pro střední hodnoty plyne, že $|\mathbb{E}(X \cdot Y)| \leq \sqrt{\mathbb{E}X^2 \cdot \mathbb{E}Y^2}$ a zvolíme-li $Y=1$,
 dostaneme $|\mathbb{E}X| \leq \sqrt{\mathbb{E}X^2} < \infty$.

Dále předpokládáme, že veličiny mají nenulový rozptyl.

KOVARIANCE - pro NV X a Y :

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X) \cdot (Y - \mathbb{E}Y)]$$

součin mezi odchylkami marginálních veličin od jejich středních hodnot

- i) $\text{cov}(X, X) = \mathbb{D}X$
 - ii) $\text{cov}(X, Y) = \text{cov}(Y, X)$
 - iii) $\text{cov}(X, Y) = \mathbb{E}(X \cdot Y) - \mathbb{E}X \cdot \mathbb{E}Y$
 - iv) $|\text{cov}(X, Y)| \leq \sqrt{\mathbb{D}X \cdot \mathbb{D}Y}$
 - v) $\text{cov}(a+b \cdot X, c+d \cdot Y) = b \cdot d \cdot \text{cov}(X, Y) \quad a, b, c, d \in \mathbb{R}$
 - vi) $\mathbb{D}(X \pm Y) = \mathbb{D}X + \mathbb{D}Y \pm 2 \cdot \text{cov}(X, Y)$
- pro nezávislé NV $\Rightarrow \text{cov}(X, Y) = 0$
- pro vícezměrnou veličinu $X = X_1, X_2, \dots, X_n$ definujeme kovarianční matici

$$\text{var } X = \begin{bmatrix} G_{11} & G_{12} & \dots & G_{1n} \\ G_{21} & G_{22} & \dots & G_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ G_{n1} & G_{n2} & \dots & G_{nn} \end{bmatrix}$$

$$G_{ij} = \text{cov}(X_i, X_j) \quad i=j: G_{ij} = \mathbb{D}X$$

KORELACE - pro NV X a Y ($\mathbb{D}X > 0, \mathbb{D}Y > 0$): $\text{cor}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\mathbb{D}X} \cdot \sqrt{\mathbb{D}Y}}$

• normovaná kovariance

- X_1, X_2 nezávislé $\Rightarrow \text{cor}(X_1, X_2) = 0$ - nekorelační veličiny
- i) $\text{cor}(X, X) = 1$
- ii) $\text{cor}(X, Y) = \text{cor}(Y, X)$
- iii) $-1 \leq \text{cor}(X, Y) \leq 1$
- iv) $\text{cor}(a+b \cdot X, c+d \cdot Y) = \text{sgn}(b \cdot d) \cdot \text{cor}(X, Y) \quad a, b, c, d \in \mathbb{R}$
- v) $\text{cor}(X, Y) = \pm 1 \Leftrightarrow Y = a \pm b \cdot X, \quad b > 0$

• korelační matice vektoru X je

$$\text{cor } X = \begin{bmatrix} 1 & g_{12} & \dots & g_{1n} \\ g_{21} & 1 & \dots & g_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ g_{n1} & g_{n2} & \dots & 1 \end{bmatrix}$$

17) VICEROZMĚRNÉ NORMÁLNÍ ROZDĚLENÍ

$X = (X_1, X_2) \sim N_2(\mu, \Sigma)$, kde $\mu = (\mu_1, \mu_2)$ je vektor středních hodnot

a $\Sigma = \begin{bmatrix} \sigma_1^2 & \rho \sigma_1 \sigma_2 \\ \rho \sigma_1 \sigma_2 & \sigma_2^2 \end{bmatrix}$ je kovarianční matice je popsáno sdruženou funkcí hustoty

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot e^{-\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} \right]}$$

- Pro dvourozměrné normální rozdělení platí:
 - **marginální rozdělení jsou normální**
 - X a Y jsou **nezávislé** právě tehdy, když jsou **nekorelované**
 $\text{cov}(X, Y) = 0 \iff X \text{ a } Y \text{ jsou nezávislé}$

18) **konvergence v pravděpodobnosti** - Posoupnost NV $\{X_n\}_{n=1}^\infty$ **konverguje v ppsti** k NV X pro $n \rightarrow \infty$ právě tehdy, když
 $\forall \varepsilon > 0: \lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$ - označíme $X_n \xrightarrow{p} X$

• **konvergence skoro jistě** - Posoupnost NV $\{X_n\}_{n=1}^\infty$ **konverguje skoro jistě** k NV X pro $n \rightarrow \infty$ právě tehdy, když
 $P(\lim_{n \rightarrow \infty} |X_n - X| = 0) = 1$ - označíme $X_n \xrightarrow{s.j.} X$

• **konvergence v distribuci** - Posoup. NV $\{X_n\}_{n=1}^\infty$ **konverguje v distribuci** k NV X pro $n \rightarrow \infty$ právě tehdy, když
 $\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$ v každém bodě, v němž je $F_X(x)$ spojitá - označíme $X_n \xrightarrow{D} X$

VĚTNY KONVERGENCÍ: i) $X_n \xrightarrow{s.j.} X \implies X_n \xrightarrow{p} X$

ii) $X_n \xrightarrow{p} X \implies X_n \xrightarrow{D} X$

iii) pokud X konstanta μ , pak $X_n \xrightarrow{D} \mu \implies X_n \xrightarrow{p} \mu$

Zákonů velkých čísel se zabývají **rozdělením průměru z NV**. Označíme $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ průměr z prvních n veličin.

• **CHEBYŠEVŮV SLABŠÍ ZÁKON VELKÝCH ČÍSEL** - Necht' X_1, X_2, X_3, \dots je posloupnost **nezávislých NV se střední hodnotou $EX_i = \mu$** a omezeným rozptylem $DX_i < C$, pak platí $\bar{X}_n \xrightarrow{p} \mu$

• **CHINČINŮV SLABŠÍ ZÁKON VELKÝCH ČÍSEL** - Necht' X_1, X_2, X_3, \dots je posloupnost **nezávislých stejne rozdělených NV se střední hodnotou $EX_i = \mu$** , pak platí $\bar{X}_n \xrightarrow{p} \mu$

• **KOLMOGOROVŮV SILNÝ ZÁKON VELKÝCH ČÍSEL** - Necht' X_1, X_2, X_3, \dots je posloup. **nezávislých stejne rozdělených NV s $EX_i = \mu$** , pak platí $\bar{X}_n \xrightarrow{s.j.} \mu$

• **CENTRÁLNÍ LIMITNÍ VĚTA** - Necht' $\{X_n\}_{n=1}^\infty$ jsou **veřejně nezávislé NV**, pro které platí $EX_i = \mu, DX_i = \sigma^2 > 0$ a $E|X_i|^3 < \infty$. Pak pro distribuční funkci NV

$$S_n = \frac{1}{\sqrt{n}} \cdot \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right) \text{ platí } \lim_{n \rightarrow \infty} P(S_n \leq x) = \Phi(x) \quad \begin{array}{l} \text{- větu lze interpretovat tak,} \\ \text{že pro velká } n \text{ přiblíží} \\ \text{platí} \end{array} \begin{array}{l} \bullet \sum_{i=1}^n X_i \approx N(n\mu, n\sigma^2) \\ \bullet \bar{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right) \end{array}$$

příklad aproximace normálních rozdělení: $Bi(n, p) \approx N(np, np(1-p))$ pro $np(1-p) \geq 9$

- Necht' $\{X_n\}_{n=1}^\infty$ jsou **veřejně nezávislé, stejne rozdělené NV s $EX_i = \mu$ a $DX_i = \sigma^2$** . Pak

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n (X_i - \mu) = \sqrt{n} (\bar{X}_n - \mu) \xrightarrow{D} N(0, \sigma^2)$$

• **CENTR. LIM. VĚTA PRO NÁHODNÉ VEKTORY** - $\{X_n\}_{n=1}^\infty$ jsou **veřejně nezávislé, stejne rozdělené k -dimensionální NV** s $EX_i = \mu$ a konvergení kovarianční matricí Σ . Pak platí $\frac{1}{\sqrt{n}} \sum_{i=1}^n (X_i - \mu) = \sqrt{n} (\bar{X}_n - \mu) \xrightarrow{D} N_k(0, \Sigma)$

Δ METODA - 1D případ - $\{T_n\}_{n=1}^\infty$ splňuje $\sqrt{n} (\bar{T}_n - \mu) \xrightarrow{D} N(0, \sigma^2)$ pro hodnoty μ, σ^2 . Pak $\sqrt{n} (g(\bar{T}_n) - g(\mu)) \xrightarrow{D} N(0, \sigma^2 \cdot (g'(\mu))^2)$

k -dimensionální - $\{T_n\}_{n=1}^\infty$ splňuje $\sqrt{n} (\bar{T}_n - \mu) \xrightarrow{D} N_k(0, \Sigma)$ pro vektor konstant μ a matici Σ .

Necht' g je spojitá diferencovatelná fce $\mathbb{R}^k \rightarrow \mathbb{R}^1$, označíme $D(g) = \frac{\partial g(x)}{\partial x}$. Pak platí

$$\sqrt{n} (g(\bar{T}_n) - g(\mu)) \xrightarrow{D} N(0, D(g(\mu)) \Sigma D(g(\mu))^T)$$

19) TRANSFORMACE NÁHODNÝCH VELICIN

- pokud X je NV a $Y=h(X)$ pak platí: $F_Y(y) = P(Y \leq y) = P(h(X) \leq y)$

- pokud $h(x)$ rostoucí: $F_Y(y) = P(Y \leq y) = P(h(X) \leq y) = P(x \leq h^{-1}(y)) = F_X(h^{-1}(y))$

a pro funkci hustoty platí $f_Y(y) = f_X(h^{-1}(y)) \cdot \left| \frac{dh^{-1}(y)}{dy} \right|$

- pro vícerozměrné NV platí $f_Y(y_1, y_2, \dots, y_m) = f_X(h_1^{-1}(y_1, \dots, y_m), \dots, h_m^{-1}(y_1, \dots, y_m)) \cdot J(y_1, \dots, y_m)$

kde $J(y_1, \dots, y_m) = \begin{vmatrix} \frac{dh_1^{-1}}{dy_1} & \frac{dh_1^{-1}}{dy_2} & \dots & \frac{dh_1^{-1}}{dy_m} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{dh_m^{-1}}{dy_1} & \dots & \dots & \frac{dh_m^{-1}}{dy_m} \end{vmatrix}$

• Necht' X je NV s pravděpodobnostní funkcí P , resp. funkcí hustoty f a necht' $h(X)$ je TRANSFORMACE NV X . Pak

střední hodnota transformované NV: DISKRETNÍ: $E[h(X)] = \sum_i h(x_i) p(X=x_i)$

STOUPNÉ: $E[h(X)] = \int h(x) f(x) dx$

SPECIÁLNÍ PŘÍPADY: - NV $Y=a+bX \rightarrow G(y) = \begin{cases} F(\frac{y-a}{b}) & b>0 \\ 1-F(\frac{y-a}{b}) & b<0 \end{cases}$

- $Y=|X| \rightarrow G(y) = \begin{cases} 0 & y<0 \\ F(y) - F_-(y) & y \geq 0 \end{cases}$

$F_-(x) = \lim_{y \rightarrow x-} F(y)$

- $Y=X^2 \rightarrow G(y) = \begin{cases} 0 & y<0 \\ F(\sqrt{y}) - F_-(\sqrt{y}) & y \geq 0 \end{cases}$

20) • Necht' X a Y jsou NV s funkcemi hustoty f_X, f_Y , pak funkce hustoty pro součet $W=X+Y$ má tvar

$g(w) = \int_{\mathbb{R}} f_X(x) f_Y(w-x) dx$

Rozdělení součtu nezávislých NV

$X_i, i=1,2,\dots,n \sim \text{Bernoulliho } A(p)$

$\dots \sum_{i=1}^n X_i \sim \text{binomické } Bi(n, p)$

$X_1 \sim Bi(n_1, p), X_2 \sim Bi(n_2, p)$

$\dots X_1 + X_2 \sim Bi(n_1 + n_2, p)$

$X_1 \sim Po(\lambda_1), X_2 \sim Po(\lambda_2)$

$\dots X_1 + X_2 \sim Po(\lambda_1 + \lambda_2)$

$X_1 \sim N(\mu_1, \sigma_1^2), X_2 \sim N(\mu_2, \sigma_2^2)$

$\dots X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$

$X_1, X_2 \sim \text{rovněžné}$

$\dots X_1 + X_2 \sim \text{trojúhelníkové}$

$X_1 \sim f_1, X_2 \sim f_2$

$\dots X_1 + X_2 \sim f(y) = \int f_1(x) f_2(y-x) dx$

Rozdělení odvozená od normálního rozdělení

• $Z_i \sim N(0,1)$ pro $i=1,2,\dots,k$ jsou NV-nezávislé, pak NV $X^2 = Z_1^2 + Z_2^2 + \dots + Z_k^2$ má X^2 rozdělení se stupněm volnosti k

$X^2 = Z_1^2 + Z_2^2 + \dots + Z_k^2 \sim \chi^2(v=k)$

• $Z \sim N(0,1)$ a $X^2 \sim \chi^2(v=n)$ jsou nezávislé NV, pak NV $T = \frac{Z}{\sqrt{X^2/n}}$ má STUDENTOVO t -rozdělení se stupněm volnosti $k = \frac{Z}{\sqrt{X^2/n}} \sim t(n)$

• $X_1^2 \sim \chi^2(v=k)$ a $X_m^2 \sim \chi^2(v=n)$ jsou nezávislé NV, pak $F = \frac{X_1^2/k}{X_m^2/n} \sim F(v_1=k, v_2=n)$ F má FISHEROVO-SNEDECOROVO ROZDĚLENÍ

• Necht' $X_i \sim F_i(x)$ jsou nezávislé NV s distribučními funkcemi F_i , pak pro NV $Y = \max(X_1, X_2, \dots, X_m)$ platí

$Y \sim F_Y(y) = F_1(y) \cdot F_2(y) \cdot \dots \cdot F_m(y)$

a pro NV $Y = \min(X_1, X_2, \dots, X_m)$ platí

$Y \sim F_Y(y) = 1 - (1 - F_1(y)) \cdot (1 - F_2(y)) \cdot \dots \cdot (1 - F_m(y))$

84) DESKRIPTIVNÍ (POPIŠNÁ) STATISTIKA

Předpokládáme, že máme k dispozici data - značíme x_1, x_2, \dots, x_n , v případě, že data budou uspořádána podle velikosti, zdůrazníme to značením $x_{(1)}, x_{(2)}, \dots$ a platí $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$.

Charakteristiky datového souboru, nazývané též **POPIŠNÉ MÍRY DAT** jsou čísla spočítaná z dat.

MÍRY POLOHY

- Průměry** - vhodné pro kvantitativní typ dat
 - ARITMETICKÝ** $\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$
 - GEOMETRICKÝ** $\bar{x}_G = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n}$
 - HARMONICKÝ** $\bar{x}_H = \left(\frac{1}{n} \sum_{i=1}^n \left(\frac{1}{x_i} \right) \right)^{-1}$

procentuální změny
průměrná rychlost
smysl pro kladná čísla
 $\bar{x}_H \leq \bar{x}_G \leq \bar{x}$

- Medián** = hodnota, kdy uspořádáme data podle velikosti
 - přesně polovina menší než medián
 - přesně polovina větší než medián

$$\tilde{x} = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ liché} \\ \frac{1}{2} (x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}) & n \text{ sudé} \end{cases}$$

- Výběrové kvantily (percentily)** = d - procentní kvantile Q_d je taková hodnota, že u dat uspořádaných podle velikosti je d procent hodnot menší než Q_d a $(100-d)$ procent hodnot je větší než Q_d kvantil.
 - Q_{25} / Q_{75} = první/horní kvartil, Q_{50} = medián, Q_{10} / Q_{90} = desátý/horní decil

- Modus** = nejčastější hodnota (=objevuje se v souboru nejčastěji)

MÍRY VARIABILITY

- rozptyl** $s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$
- výběrový rozptyl** $S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} (\sum_{i=1}^n x_i^2 - n\bar{x}^2)$

- výběrová směrodatná odchylka** $s = \sqrt{s^2}$
- výběrový variační koeficient** $W = \frac{s}{\bar{x}}$

- rozsáhlost** $R = Q_{100} - Q_0 = x_{(n)} - x_{(1)} = \max(x) - \min(x)$
- kvartilové / decilové rozsáhlosti** $R_Q = Q_{75} - Q_{25} / R_D = Q_{90} - Q_{10}$

- průměrná absolutní odchylka od mediánu** $d_x = \frac{1}{n} \sum_{i=1}^n |x_i - \tilde{x}|$

- statistická entropie (Claude Shannon)** - vhodné zejména pro kvalitativní data, využitelná v teorii informací $H = -\sum_{i=1}^m \frac{n_i}{n} \log_2 \left(\frac{n_i}{n} \right)$ kde n_j jsou existující nenulové četnosti hodnot měřené veličiny. Pro $b=2$ v bitech, $b=e$ v mapech, $b=10$ v bemech. Entropii lze normalizovat vydělením délkou informace \rightarrow měrná entropie = míra náhodnosti informace

- funkce** $S(t) = \frac{1}{n} \sum_{i=1}^n (x_i - t)^2$ nabývá minima $\Leftrightarrow t = \bar{x}$.

$$T(t) = \frac{1}{n} \sum_{i=1}^n |x_i - t| \text{ nabývá minima } \Leftrightarrow t = \tilde{x}$$



- Entropie maximální** $\Leftrightarrow \frac{n_1}{n} = \frac{n_2}{n} = \dots = \frac{n_m}{n}$

VIZUALIZAČNÍ NÁSTROJE


- Matplotlib** - jazyk Python
- Seaborn** - Python, postavena na Matplotlib
- Plotly** - Python, R
- ggplot2** - R

STATISTICKÉ GRAFY

- Histogram**



- Empirical distribuční fce**



- Probability plot**



22) NÁHODNÝ VÝBĚR - vektor X_1, X_2, \dots, X_n složený z n nezávislých stejně rozdělených NV můžeme

NÁHODNÝ VÝBĚR ROZSAHU n

- NV X_i jsou popsány distribuční funkcí (případně hustoty / pravděpodobnostní) s parametry $\theta = (\theta_1, \dots, \theta_k)$, tedy $X_i \sim F(\theta_1, \theta_2, \dots, \theta_k)$. Střední hodnota μ , rozptyl $\sigma^2(\theta)$, kde θ jsou parametry rozdělení
- realizace náhodného výběru x_1, x_2, \dots, x_n tvoří datový soubor
- náhodný výběr a datový soubor lze popsat pomocí charakteristik z funkce výběru X_1, X_2, \dots resp. funkce hodnot dat. souboru

STATISTIKA - libovolnou NV T_n , která vznikne jako funkce náhodného výběru X_1, \dots, X_n můžeme statistikou $T_n = T(X_1, \dots, X_n)$

VÝBĚROVÉ CHARAKTERISTIKY - Necht' x_1, x_2, \dots, x_n je náhodný výběr rozsahu n z rozdělení s distribuční funkcí $F(x, \theta)$.

Tak statistika

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

výběrový průměr

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

výběrový rozptyl

$$S_n = \sqrt{S_n^2}$$

výběrová směrodatná odchylka

Střední hodnota a rozptyl výběrového průměru a rozptylu - Necht' X_1, \dots, X_n je náhodný výběr rozsahu n z rozdělení se střední hodnotou $\mu = \mu(\theta)$ a rozptylem $\sigma^2 = \sigma^2(\theta)$. Pak

i) výběrový průměr: $E(\bar{X}_n) = \mu$ $D(\bar{X}_n) = \sigma^2/n$

ii) výběrový rozptyl: $E(S_n^2) = \sigma^2$ $D(S_n^2) = \frac{\mu_4}{n} - \frac{\sigma^4(n-3)}{n(n-1)}$, kde μ_4 je čtvrtý centrální moment, $\mu_4 = E[(X - \mu)^4]$

ROZDĚLENÍ VÝBĚROVÝCH CHARAKTERISTIK - pro náhodný výběr rozsahu n z normálního rozdělení $X \sim N(\mu, \sigma^2)$ platí:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{má rozdělení} \quad N(\mu, \sigma^2/n) - \text{normální}$$

$$Z = \frac{\bar{X}_n - \mu}{\sigma} \sqrt{n} \quad N(0,1) - \text{normální}$$

$$t = \frac{\bar{X}_n - \mu}{S_n} \sqrt{n} \quad t(n-1) - \text{Studentovo } t\text{-rozdělení se stupněm volnosti } \nu = n-1$$

$$\frac{(n-1)S_n^2}{\sigma^2} \quad \chi^2(n-1) - \chi^2 \text{ rozdělení se st. volnosti } \nu = n-1$$

23) BODOVÝ ODHAD - Uvažujeme NV X s fci hustoty $f(x, \theta)$ s neznámým parametrem θ .

Pro bodový odhad θ rozumíme jakoukoliv statistiku (fci) $\theta_{Tn} = T(X_1, \dots, X_n)$, která závisí na θ .

Pro bod. odhad θ založený na statistice θ_{Tn} a dané realizaci výběru je hodnota statistiky T s dosazenou realizací x a značíme $\hat{\theta} = \theta_{Tn}(x)$.

Vlastnosti i) statistika $T = \theta_{Tn}$ poskytuje **nestranný odhad**, pokud platí $E(T(X_1, \dots, X_n)) = \theta$ \forall možného θ .
Vychýlený odhad $\text{Bias}[\theta_{Tn}]$ je rozdíl mezi střední hodnotou odhadu a odhadovým parametrem

$$\text{Bias}[\theta_{Tn}] = E[\theta_{Tn}(X_1, X_2, \dots, X_n)] - \theta$$

Střední kvadratická chyba odhadu je $\text{MSE}(\theta_{Tn}) = E(\theta_{Tn} - \theta)^2 = D(\theta_{Tn}) - (\text{Bias}(\theta_{Tn}))^2$

ii) statistika T poskytuje **konzistentní odhad**, pokud s rostoucím n „zpřesňujeme odhad“, tj.

$$\lim_{n \rightarrow \infty} P(|\theta_{Tn} - \theta| < \epsilon) = 1 \quad \forall \text{ možného } \theta$$

iii) statistika θ_{Tn} poskytuje **lepší odhad** než statistika θ_{Un} , pokud $D(\theta_{Tn}) < D(\theta_{Un})$

• Nechť statistika θ_{Tn} je nestranný nebo asymptoticky nestranný odhad parametru θ a platí $\lim_{n \rightarrow \infty} D(\theta_{Tn}) = 0$.
Pak θ_{Tn} je konzistentním odhadem θ

INTERVALOVÉ ODHADY - Platí-li pro statistiky $D = D(X_1, \dots, X_n)$ a $H = H(X_1, \dots, X_n)$ vztah $P(D \leq \theta \leq H) = 1 - \alpha$

říkáme, že $(D; H)$ je **intervalovým odhadem parametru θ** s koeficientem spolehlivosti $1 - \alpha$.

Intervaly tvaru $(D; H)$ se nazývají **dvoustranné**, tvaru $(-\infty; H)$ / $(D; +\infty)$ **jednostranné**. Přesnost je dána $1H - D$

• pro parametr μ normálního rozdělení (známý rozptyl σ^2) $\bar{x} \pm u_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}$
(neznámý σ^2) $\bar{x} \pm t_{1-\frac{\alpha}{2}}(v = n-1) \cdot \frac{s}{\sqrt{n}}$

• pro parametr σ^2 normálního rozdělení $\left(\frac{(n-1)s^2}{\chi^2_{1-\frac{\alpha}{2}}(v=n-1)} ; \frac{(n-1)s^2}{\chi^2_{\frac{\alpha}{2}}(v=n-1)} \right)$

• pro parametr p alternativního rozdělení $\hat{p} \pm u_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

24) METODY KONSTRUKCE BODOVÝCH ODHADŮ

• **KOMENTOVÁ METODA** - porovnává momenty NV a výběrové momenty

• **METODA MAXIMÁLNÍ VĚROHODNOSTI** - založena na maximalizaci věrohodnostní funkce L , kde tato funkce pro náhodný výběr má tvar

$$L(\theta) = \prod_{i=1}^n f(x_i, \theta) = f(x_1, \theta) \cdot f(x_2, \theta) \cdot \dots \cdot f(x_n, \theta)$$

25) FORMULACE STATISTICKÝCH HYPOTÉZ

• na základě realizace náh. výběru X_1, X_2, \dots, X_n rozsahu n ověřujeme určitou hypotézu týkající se NV X .

• statistická hypotéza je tvrzení o parametrech (parametrické testy) pozorované NV pocházející ze základního souboru
o tvaru rozdělení znaku v základním souboru (nepar. testy) na základě pozorované NV

• testování statist. hypotéz je jednoduchý rozhodovací postup, při němž se na základě výsledků získaných náhodným výběrem vyvolíme buď pro testovanou (nulovou) hypotézu nebo pro alternativní hypotézu

CHYBY I. a II. DRUHU u STATISTICKÝCH TESTŮ

úsudek o H_0	skutečnost	
	H_0 je pravdivá	H_0 je nepravdivá
nezamítá se H_0	<p>správné rozhodnutí</p> <p>$P = 1 - \alpha$</p>	<p>chyba II. druhu</p> <p>$P = \beta$ ← dopočítává se</p>
zamítá se H_0	<p>chyba I. druhu</p> <p>$P = \alpha$ ← pevně</p>	<p>správné rozhodnutí</p> <p>$P = 1 - \beta$ ← síla testu</p>

α - ppst. chyby I. druhu

β - ppst. chyby II. druhu

26) **STATISTICKÉ TESTOVÁNÍ** - Předpokládáme, že X_1, X_2, \dots, X_n je nezávislý výběr z rozdělení s distribuční funkcí F_θ , $\theta \in \Theta$. Dále předpokládáme, že o parametru θ \exists dvě konkurující si hypotézy H_0 je $\theta \in \Theta_0$ a H_1 je $\theta \in \Theta - \Theta_0$. Testem rozumíme rozhodovací postup, který nám na základě realizace máh. výběru umožní zamítnout nebo nezamítnout platnost hypotézy H_0 .

Rozhodovací algoritmus testu

- **testová statistika** = stat. výpočet z máh. výběru $T = T(X_1, X_2, \dots, X_n)$
- statistické rozhodování probíhá na základě **kritického oboru** W , kdy kritický obor volíme tak, aby při platnosti H_0 hodnota testové statistiky padla do \uparrow co nejčastěji a při platnosti H_0 zřídka
pokud $T \in W \rightarrow$ zamítám nulovou hypotézu a pokud $T \notin W \rightarrow$ nezamítám H_0
- velikost W volíme tak, abychom platnou hypotézu H_0 zamítali nejvýše s ppstí α - jedná se o **maximální povolenou chybu I. druhu** a nazýváme ji **hladinou testu**
volíme obvykle $\alpha = 5\%$ (případně 1% nebo 10%)
- výpočetní SW poskytují info o **nejmenší hladině**, při které bychom hypotézu H_0 zamítli, tato nejmenší hladina se nazývá **p-hodnota testu**
 - udává **mezní hodnotu hladiny významnosti**, při které zamítáme H_0
 - H_0 zamítáme na hladině $\alpha \iff$ hodnota $p < \alpha$
 - nízké hodnoty $p \rightarrow$ zamítám nulovou hypotézu
 - vysoké p-hodnoty \rightarrow nezamítám nulovou hypotézu

27) JEDNOVÝBĚROVÉ PARAMETRICKÉ TESTY

• Test o střední hodnotě při známém rozptylu ... **Z-test**

- Pokud X_1, \dots, X_n je máh. výběr z normálního rozdělení se známým rozptylem σ^2

nulová hypotéza H_0	alternativní H_1	testová statistika $T(X_1, X_2, \dots, X_n)$	kritický obor $T \in W$
$\mu = \mu_0$	$\mu \neq \mu_0$ $\mu > \mu_0$ $\mu < \mu_0$	$U = \frac{\bar{x} - \mu_0}{\sigma} \sqrt{n}$	$ U > u_{1-\alpha/2}$ $U > u_{1-\alpha}$ $U < -u_{1-\alpha}$

• Test o střední hodnotě při neznámém rozptylu ... **T-test**

H_0	H_1	$T(X_1, \dots, X_n)$	$T \in W$
$\mu = \mu_0$	$\mu \neq \mu_0$ $\mu > \mu_0$ $\mu < \mu_0$	$T = \frac{\bar{x} - \mu_0}{s} \sqrt{n}$	$ T > t_{1-\alpha/2} (v=n-1)$ $T > t_{1-\alpha} (v=n-1)$ $T < -t_{1-\alpha} (v=n-1)$

• Test o rozptylu - neznámá střední hodnota

H_0	H_1	$T(X_1, \dots, X_n)$	$T \in W$
$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$ $\sigma^2 > \sigma_0^2$ $\sigma^2 < \sigma_0^2$	$T = \frac{(n-1)s^2}{\sigma_0^2}$	$T \in (\chi^2_{\alpha/2} (v=n-1); \chi^2_{1-\alpha/2} (v=n-1))$ $T > \chi^2_{1-\alpha} (v=n-1)$ $T < \chi^2_{\alpha} (v=n-1)$

28 DVOUVÝBĚROVÉ PARAMETRICKÉ TESTY

- Test o shodě středních hodnot - **T-test** - X_1, \dots, X_{m_1} je náh. výběr z normálního rozdělení $N(\mu_1, \sigma^2)$ a Y_1, \dots, Y_{m_2} je náh. výběr z $N(\mu_2, \sigma^2)$

nulová hypotéza H_0	alternativní H_1	testová statistika T	kritický obor $T \in W$
	$\mu_1 \neq \mu_2$	$T = \frac{\bar{x} - \bar{y}}{\sqrt{S_1^2/m_1 + S_2^2/m_2}}$	$ T > t_{1-\alpha/2} \quad (\nu = \min(m_1, m_2) - 1)$
$\mu_1 = \mu_2$	$\mu_1 > \mu_2$		$T > t_{1-\alpha} \quad (\nu = \min(m_1, m_2) - 1)$
	$\mu_1 < \mu_2$		$T < -t_{1-\alpha} \quad (\nu = \min(m_1, m_2) - 1)$

- Test o shodě rozptylů - **F-test** - $\mu_1 = \mu_2$

H_0	H_1	T	$T \in W$
$\sigma_1^2 = \sigma_2^2$	$\sigma_1^2 \neq \sigma_2^2$	$F = S_1^2 / S_2^2$	$F \notin (F_{\alpha/2} ; F_{1-\alpha/2}) \quad (\nu_1 = m_1 - 1, \nu_2 = m_2 - 1)$
	$\sigma_1^2 > \sigma_2^2$		$F > F_{1-\alpha} \quad (\nu_1 = m_1 - 1, \nu_2 = m_2 - 1)$
	$\sigma_1^2 < \sigma_2^2$		$F < F_{\alpha} \quad (\nu_1 = m_1 - 1, \nu_2 = m_2 - 1)$

- Test o koeficientu korelace (lineární závislosti) - Pro NV X a Y lze lineární vazbu vyjádřit pomocí kovariance

$$\text{cov}(X, Y) = E[(X - EX) \cdot (Y - EY)] = E(XY) - E(X) \cdot E(Y) \quad \text{nebo korelace}$$

$$\text{cor}(X, Y) = \rho = \frac{\text{cov}(X, Y)}{\sqrt{\text{D}(X) \cdot \text{D}(Y)}}$$

- Pearsonův koeficient korelace - Pokud $(X_1, Y_1), (X_2, Y_2), \dots, (X_m, Y_m)$ je náhodný výběr z dvourozměrného rozdělení, pak Pearsonův koeficient korelace je definován

$$r = \frac{\sum_{i=1}^m (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^m (X_i - \bar{X})^2} \cdot \sqrt{\sum_{i=1}^m (Y_i - \bar{Y})^2}}$$

\bar{X}, \bar{Y} - aritmetické průměry prvních a druhých měření

- ekvivalentně lze vyjádřit pomocí součinů z-skórů

$$r = \frac{1}{m-1} \sum_{i=1}^m \left(\frac{X_i - \bar{X}}{s_x} \right) \left(\frac{Y_i - \bar{Y}}{s_y} \right), \quad s_x = \sqrt{\frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2} \quad \text{směrodatná odchylka}$$

- v případě, kdy 1 ze znaki je binární (mapř. sledujeme-li závislost binární položky Y a celkového počtu bodů X , tzv. index RIT) se kor. koef. redukuje na **bodově-biserialní korelační koef.**

$$r_{\text{bis}} = \frac{(\bar{X}_1 - \bar{X}_0)(m_0 m_1)}{s \cdot n \cdot (n-1)}$$

\bar{X}_1 - průměr celkového počtu bodů studentů, kteří mají hodnotu sledované položky rovnou 1

\bar{X}_0 - " " " " rovnou 0

s^2 - STD odchylka celkových bodových zisků, $m_1 \neq 1$, $m_0 \neq 0$

- Pokud $(X_1, Y_1), \dots, (X_n, Y_n)$ je náh. výběr z dvourozměrného normálního rozdělení, kde kor. koeficient $\rho = 0$

H_0	H_1	T	$T \in W$
$\rho = 0$	$\rho \neq 0$	$R = \frac{r}{\sqrt{1-r^2}} \cdot \sqrt{n-2}$	$ R > t_{1-\alpha/2} \quad (\nu = n-2)$
	$\rho > 0$		$R > t_{1-\alpha} \quad (\nu = n-2)$
	$\rho < 0$		$R < -t_{1-\alpha} \quad (\nu = n-2)$

29) χ^2 TEST DOBRÉ SHODY

H_0 ppsí výsledků jsou p_1, p_2, \dots, p_k (data mají rozdělení dané tímto ppsím). Porovnáváme očekávané četnosti $m_i^0 > 5$ určené pomocí ppsí p_i a naměřené četnosti n_i . Postup je:

- rozdelíme obor hodnot NV X na k nepřekrývajících se tříd
- zjistíme, kolik hodnot realizovaného náh. výběru se nachází v jednotlivých třídách. Počty prvků v jednotlivých třídách označíme n_i
- podle j , $m_j > 0$ parametrické rozdělení známých \rightarrow odhadneme je (k dispozi máme tedy po tomto kroku ppsí p_i dané tímto rozdělením)
- pro každou třídu spočítáme očekávaný # hodnot v této třídě, ozh. m_i^0 . Platí $m_i^0 = n \cdot p_i$
- v případě že je v některé třídě # očekávaných hodnot $< 5 \rightarrow$ tuto třídu sdružíme s jinou
- testovací statistika má tvar $\chi^2 = \sum_{i=1}^k \frac{(n_i - m_i^0)^2}{m_i^0}$
- test. statistika má za platnosti H_0 asymptoticky χ^2 -rozdělení se stupněm volnosti $v = k - 1 - m$
- hypotézu, že se NV řídí předpokládaným modelem zamítáme na hladině významnosti α , je-li $\chi^2 > \chi^2_{1-\alpha}(v)$ kde $\chi^2_{1-\alpha}(v)$ je kvantil χ^2 rozdělení s volností $v = k - 1 - m$

30) TESTOVÁNÍ NEZÁVISLOSTI

- Testujeme nezávislost 2 NV X a Y , pro které máme k dispozi údaje o četnostech n_{ij} obsažené v kontingenci tabulce

	y_1	y_2	...	y_j	součty
x_1	n_{11}	n_{12}	...	n_{1j}	$n_{1\cdot}$
x_2	n_{21}	n_{22}	...	n_{2j}	$n_{2\cdot}$
...
x_I	n_{I1}	n_{I2}	...	n_{Ij}	$n_{I\cdot}$
součty	$n_{\cdot 1}$	$n_{\cdot 2}$...	$n_{\cdot j}$	n

- Při platnosti nezávislosti lze očekávané četnosti vypočítat podle vztahu (požadujeme $m_{ij}^0 > 5$)
 $m_{ij}^0 = \frac{n_{i\cdot} \cdot n_{\cdot j}}{n}$
- testovací statistika má tvar: $\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - m_{ij}^0)^2}{m_{ij}^0}$
- test. stat. má za platnosti nulové hypotézy (nezávislost obou veličin) asymptoticky χ^2 -rozdělení se stupněm volnosti $v = (I-1)(J-1)$
- hypotézu, že se NV nezávisle, zamítáme na hladině významnosti α , je-li $\chi^2 > \chi^2_{1-\alpha}(v)$ kde $\chi^2_{1-\alpha}(v)$ je kvantil χ^2 rozdělení s volností $v = (I-1)(J-1)$

31) LINEÁRNÍ REGRESNÍ MODEL

- zjišťujeme, zda hodnoty Y (vysvětlovaná proměnná) závisí na hodnotě X (vysvětlující prom.)
uvádíme model $Y = f(\beta_0, \beta_1, \dots, \beta_k; x) + \varepsilon$, kde $\varepsilon \sim N(0, \sigma^2)$ reprezentuje nesymetrické chyby.

Model odhadujeme na základě sady měření $(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)$

Příklady lineárních modelů

- $Y = \beta_0 + \beta_1 x + \varepsilon$ - lineární model
- $Y = \beta_0 + \beta_1 \ln(x) + \varepsilon$ - logaritmický m.
- $Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$ - polynomiální stupně 2
- $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon$ - modely s více vysvětlujícími proměnnými

Příklady nelineárních modelů

- $Y = \beta_0 \cdot e^{\beta_1 x} + \varepsilon$ - exponenciální
- $Y = \beta_0 \cdot x^{\beta_1} + \varepsilon$ - mocninový

MATICOVÝ ZÁPIS LIN. REG. MODELU

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & \dots & x_{1k} \\ 1 & x_{21} & \dots & x_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{m1} & \dots & x_{mk} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_m \end{bmatrix}$$

matice typu $n \times (k+1)$
hodnot vysvětlujících proměnných - regresní matice,
sloupců = $p = k+1$

β = vektor hledaných $k+1$ parametrů

$Y = [y_1, y_2, \dots, y_m]^T$ je vektor vysvětlované proměnné

Předpoklady regresního modelu a normálního reg. modelu

- (P1) $E(\varepsilon_i) = 0 \quad \forall i=1,2,\dots,m$
- (P2) $D(\varepsilon_i) = \sigma^2$ a $cov(\varepsilon_i, \varepsilon_j) = 0$ pro $i \neq j$
(*) $M = P_2$ $\varepsilon \sim N(0, \sigma^2 I_n)$
- (P3) \nexists přesná lineární vazba mezi sloupci matice, matice X má plnou hodnost
- (P4) X je nestochastická

32) ODHAD PARAMETRŮ LIN. REG. MODELU

$\beta_0, \beta_1, \dots, \beta_k$ lze odhadnout např. metodou nejmenších čtverců, která minimalizuje výraz

$$S(\beta_0, \dots, \beta_k) = \sum_{i=1}^n (y_i - f(\beta_0, \beta_1, \dots, \beta_k; x_i))^2$$

• **Gaussova Markovova věta** - uvažujeme LIN. REG. M. v maticovém tvaru $Y = X\beta + \varepsilon$ s předpoklady (P1)-(P4)

i) odhad param. metodou nejmenších čtverců má tvar $b = (X^T X)^{-1} X^T Y$

ii) b je nestranným odhadem β (tj. $E(b) = \beta$) a $D(b) = \sigma^2 (X^T X)^{-1}$

iii) $S_R^2 = \frac{RSE}{n-k-1}$ je nestranným odhadem σ^2 (tj. $E(S_R^2) = \sigma^2$), kde $RSE = (Y - Xb)^T (Y - Xb)$ - reziduální součet čtverců odchylek

• **Gaussova Markovova věta s předpokladem normality** - uvažujeme LIN. REG. NORMALNÍ MODEL v maticovém tvaru

$Y = X\beta + \varepsilon$ s předpoklady $(P_1 + P_2) - (P_4)$. Pak

i) $b \sim N(\beta; \sigma^2 (X^T X)^{-1})$

ii) $\frac{RSE}{\sigma^2} = \frac{S_R^2 (n-k-1)}{\sigma^2} \sim \chi^2$ se stupni volnosti $\nu = n-k-1$

iii) Pro $j=0, 1, \dots, k$ platí $\frac{b_j - \beta_j}{\sqrt{S_R^2 \cdot \text{diag}_j(X^T X)^{-1}}} \sim t(\nu = n-k-1)$ kde $\text{diag}_j(X^T X)^{-1}$ je prvek na pozici jj matice $(X^T X)^{-1}$

• Pro lin. reg. model označme

• $TSS = \sum_{i=1}^n (y_i - \bar{y})^2$ - celkový součet čtverců $\rightarrow S_T^2 = \frac{TSS}{n-1}$ celkový rozptyl

Platí:
 $TSS = ESS + RSE$

• $ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ - vysvětlenný součet čtverců $\rightarrow S_E^2 = \frac{ESS}{k}$ regresní rozptyl

• $RSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ - reziduální součet čtverců odchylek $\rightarrow S_R^2 = \frac{RSE}{n-k-1}$ reziduální rozptyl

33) KOEFICIENT DETERMINACE $R^2 = 1 - \frac{RSE}{TSS}$, UPRAVENÝ KOEF. DET. $R_a^2 = 1 - \frac{RSE/(n-k-1)}{TSS/(n-1)}$

Pro koef. det. platí i) $R^2 = \frac{ESS}{TSS} = \frac{S_E^2(k)}{S_T^2(n-1)} = 1 - \frac{S_R^2(n-k-1)}{S_T^2(n-1)}$

pro \uparrow platí: $R_a^2 = 1 - \frac{S_R^2}{S_T^2}$

ii) $0 \leq R^2 \leq 1$

iii) $k=1$ (přímková regrese) platí $\sqrt{R^2} = |r|$,

kde r je výběrový korelační koeficient

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

34) • Pro test významnosti regrese, kde $H_0: \beta_1 = \beta_2 = \dots = \beta_k$ ver. H_1 : alespoň 1 koef. je nenulový

se využívá testová statistika $F = \frac{S_E^2}{S_R^2} = \frac{ESS/k}{RSE/(n-k-1)} = \frac{R^2}{1-R^2} \cdot \frac{n-k-1}{k}$

kde $F|_{H_0} \sim F(\nu_1 = k, \nu_2 = n-k-1)$ Fisherovo rozdělení

• Pro test významnosti pro jednotlivé koeficienty, kde $H_0: \beta_j = 0$ ver. $H_1: \beta_j \neq 0$ se využívá

testová statistika $t = \frac{b_j}{\text{se}(b_j)}$

↑
směrodatná odchylka odhadu koeficientu $\text{se}(b_j) = \sqrt{S_R^2 \cdot \text{diag}_j(X^T X)^{-1}}$

a platí $t|_{H_0} \sim t(\nu = n-k-1)$